

DermAgentBench v1

最低成本建设方案

基于现有皮肤病公开数据的 benchmark overlay + episode 环境设计

目标：不重新采图、不重走招募流程，直接在现有图像/metadata 之上补齐 agent layer。

v1 设计原则

- 1. 不从零采图，而是在现有公开/可下载数据上叠加 benchmark layer。
- 2. 先做两条主线：DermReasonBench-Core（静态/半静态推理）与 DermAgentBench-Lite（轻量交互）。
- 3. 只补最关键字段：safe differential contraction、high-risk miss、grounded evidence、ask-for-more-info、referral、budgeted acquisition。
- 4. 公开一部分、隐藏一部分；对许可严格的数据集只做隐藏评测或 ontology 借用。
- 5. v1 先追求“可发表、可复现、可启动”，而不是大而全。

模块	v1 目标
公开主干数据	PAD-UFES-20 + MCR-SL
隐藏精测数据	MRA-MIDAS + DDI/DermaBench 子集
样本规模	约 480 个 episode；其中 120 个 groundedness 子集
交互形式	10-12 个 dermatology-specific atomic actions；不做自由对话
核心卖点	safe contraction、referral、groundedness、信息获取与成本收益

1. v1 范围与产出

v1 只做两个最小但完整的 benchmark：DermReasonBench-Core 与 DermAgentBench-Lite。前者面向静态或半静态推理，后者面向最基本的交互式 agent 行为。这样既能覆盖论文主卖点，又能把标注与工程复杂度控制在可接受范围内。

DermReasonBench-Core 重点评估：候选收缩是否合理、高风险病例是否漏检/过早闭合、证据是否 grounded、最终 diagnosis 与 referral 是否安全。DermAgentBench-Lite 重点评估：是否会 asking for more info、是否会请求更有价值的额外模态、是否会 stop / continue / refer，以及多一步信息获取带来的收益是否值得额外成本。

2. 最低成本数据栈

数据源	建议角色	低成本价值	使用/发布建议
PAD-UFES-20	公开主干 clinical-photo 集	手机临床图 + metadata + 高风险标签；适合静态 reasoning、恶性漏检与 referral	公开开发集；可直接用于 public split
MCR-SL	Interactive-Lite 主力集	clinical + dermoscopy 配对；已有 referral_diagnosis、2nd option、certainty、metadata	公开主干；适合构建 request-dermoscopy 与 asking-for-more-info
MRA-MIDAS	隐藏精测 differential contraction 集	有 top-five clinical impressions、confidence、paired clinical+dermoscopy、病理支持	建议只做 hidden leaderboard 子集
DDI / DermaBench	隐藏 fairness / groundedness 审计集	多肤色、pathology-confirmed；DermaBench 提供 morphology/narrative ontology	不作为公开图像主干；只做 hidden audit 或 ontology 借用

v1 推荐的最小可发表组合是：公开主干 = PAD-UFES-20 + MCR-SL；隐藏精测 = MRA-MIDAS + DDI/DermaBench 子集。这样既能保证可公开复现，又能保留高质量 hidden test 来提升 leaderboard 含金量。

如果必须进一步压缩预算，可以先做 PAD-UFES-20 + MCR-SL 的公开版本，并把 MRA-MIDAS 和 DDI/DermaBench 放入后续扩展或内部验证。

3. 建议样本规模与配比

分区	数量	用途
公开开发集	300	PAD-UFES-20: 200；MCR-SL: 100
隐藏测试集	180	PAD-UFES-20: 40；MCR-SL: 40；MRA-MIDAS: 60；DDI/DermaBench: 40
Groundedness 子集	120	仅用于 claim-source / key visual anchor / unsupported claim 审计

建议控制高风险 / do-not-miss 病例占比在 35%-40%，confusable pairs 占比约 30%，必须 asking-for-more-info 才安全的病例占比 25%-30%。这样 benchmark 会更贴近临床安全需求，而不是被 easy canonical cases 主导。

4. 每个 case 需要补的字段

A. Core Overlay（全量必做）

字段组	内容
-----	----

自动预填	source_dataset ; subject/lesion/image ID ; available_modalities ; gold_primary_dx ; biopsy_confirmed ; 年龄/性别/部位/肤色/大小 ; raw_metadata_json ; 已有 expert options 或 certainty
专家补充	acceptable_differential (2-5 个) ; critical_do_not_miss (0-3 个) ; risk_tier ; safe_to_finalize_at_t0 ; if_not_safe_best_next_action ; final_referral_label ; harm_weight_if_missed ; overreferral_burden

B. Episode Overlay（只给 Interactive-Lite case）

字段	内容
episode state	visible_at_t0 ; hidden_slots ; stop_condition ; refer_immediately_allowed
动作标签	must_ask_actions ; useful_but_optional_actions ; low_value_actions ; unsafe_to_finalize_before_actions
动作集合	ASK_DURATION ; ASK_CHANGE ; ASK_BLEED_OR_ULCERATION ; ASK_ITCH_OR_PAIN ; ASK_NEW_OR_OLD ; ASK_PERSONAL_OR_FAMILY_SKIN_CANCER ; ASK_IMMUNOSUPPRESSION ; ASK_SUN_EXPOSURE_OR_SUNBURN ; REQUEST_DERMOSCOPY ; REQUEST_CLOSEUP_OR_CONTEXT ; REFER_NOW ; FINALIZE

C. Evidence Overlay（只给 groundedness 子集）

字段	内容
finding / source	visible_findings_checklist ; metadata_only_claims ; claim_source_map (image / metadata / acquired)
风险审计	unsupported_dangerous_claims ; contradictory_claim_pairs
轻量视觉定位	key_visual_anchor (point / bbox / short textual anchor)

5. 专家标注模板（可直接试标）

模板 1：Core Clinical Gold（全量）

1. Primary diagnosis
2. Acceptable differential（最多 5 个）
3. Critical do-not-miss candidates（最多 3 个）
4. Risk tier：benign / low-risk / uncertain-needs-more-info / likely malignant / urgent
5. t0 信息是否足以安全 finalize：yes / no
6. 若 no，最优下一步动作
7. Final referral：self-care / PCP / routine dermatology / urgent dermatology / biopsy needed / emergency
8. Harm weight if missed：1 / 3 / 5
9. Over-referral burden：1 / 2 / 3
10. Optional notes

模板 2：Episode / Must-Ask（只给交互例）

对每个动作标注：Must-ask / Useful but optional / Low-value / Misleading or unnecessary / Not available。
动作列表：ASK_DURATION；ASK_CHANGE；ASK_BLEED_OR_ULCERATION；ASK_ITCH_OR_PAIN；ASK_NEW_OR_OLD；ASK_PERSONAL_OR_FAMILY_SKIN_CANCER；ASK_IMMUNOSUPPRESSION；ASK_SUN_EXPOSURE_OR_SUNBURN；REQUEST_DERMOSCOPY；REQUEST_CLOSEUP_OR_CONTEXT；REFER_NOW；FINALIZE。
补充问题：哪些动作前 finalize 属于不安全；哪个动作的信息增益最大；是否可以直接 referral。

模板 3：Grounded Evidence Audit（只给 groundedness 子集）

1. 图像中明确可见的 finding
2. 只能由 metadata 支持的 claims
3. 当前输入绝对不应支持的危险 claim
4. 关键 claim 的来源标注：image / metadata / acquired
5. 可选 visual anchor（point / box / short note）

6. 数据源到任务的映射建议

数据源	推荐承担任务
PAD-UFES-20	clinical-photo-only reasoning；high-risk miss；referral；部分 asking-for-more-info（仅在 metadata 足够时）
MCR-SL	request dermoscopy；uncertainty；episode 交互；referral；cost-aware acquisition
MRA-MIDAS	safe differential contraction；hidden leaderboard；专家候选集对齐
DDI/DermaBench	fairness audit；groundedness audit；morphology / narrative consistency

最低成本原则是：PAD 负责公开临床图主干，MCR-SL 负责轻交互，MRA-MIDAS 负责高质量 hidden differential contraction，DDI/DermaBench 负责 fairness 与 groundedness 审计。不要试图让任何一个数据源承担全部任务。

7. patient simulator 与环境实现（Lite 版）

交互环境不做自由对话，而采用 atomic fact table + 规范化 action ontology。每个 action 只返回一个受控槽位：例如 ASK_CHANGE 返回“是否近期变化 + 简短描述”，REQUEST_DERMOSCOPY 返回一张 dermoscopy 图的 image_id。

unknown / unavailable 一律返回固定模板，如“信息未提供”或“该模态不可用”。这样可以显著降低 simulator hallucination 与评分歧义。

官方提交接口要求模型在每一步返回结构化 workspace：observed_findings、current_differential、critical_do_not_miss、missing_information、requested_actions、referral_level、final_decision、uncertainty、stop_reason。这样无需暴露私有 chain-of-thought，同时又保留可审计性。

8. 标注流程与时间预算

阶段	工作内容	建议时长
第 1-2 周	数据审核、去重、统一 lesion-centric schema、筛选 480 个候选 case	2 周
第 3 周	RA 预填自动字段与 annotation sheet	1 周
第 4-6 周	专家完成模板 1 与模板 2；groundedness 子集开始模板 3	3 周
第 7 周	仲裁高分歧字段：differential / risk / referral / must-ask / groundedness	1 周
第 8-9 周	搭建 Lite 环境、atomic fact simulator、评分器	2 周
第 10 周	baseline、sanity check、隐藏评测跑通	1 周

按 480 个 case 估算，在前处理足够充分的前提下，临床专家总投入大约 120-150 小时即可启动 v1：模板 1 约 80 小时，模板 2 约 12 小时，模板 3 约 12 小时，外加 15-25 小时仲裁。

9. 发布策略与风险控制

问题	建议
数据许可	公开发布 PAD-UFES-20 与 MCR-SL 的 case mapping、schema 与代码；DDI/DermaBench 仅做 hidden audit；MRA-MIDAS 优先作为 hidden leaderboard
benchmark contamination	采用 hosted evaluation 或 hidden test server；避免完整测试图和答案同时公开
标注成本	全量只做 Core Overlay；Episode 与 Groundedness 只做子集
环境复杂度	v1 不做自由对话；只保留 10-12 个 dermatology-specific atomic actions

10. v1 的最终建议版本

推荐落地组合

数据骨架：公开主干 = PAD-UFES-20 + MCR-SL；隐藏精测 = MRA-MIDAS + DDI/DermaBench 子集。
标注层：全量做 Core Overlay；交互例做 Episode Overlay；小子集做 Groundedness Overlay。
环境：不做自由对话，只做 10-12 个 atomic actions 与 hidden test server。
论文卖点：首个专门评估 dermatology agent 的 benchmark，强调 safe differential contraction、high-risk miss、grounded evidence、ask-for-more-info、referral 与 cost-performance tradeoff。

参考数据与方向（用于 v1 设计）：PAD-UFES-20；MCR-SL；MRA-MIDAS；DDI /
DermaBench；PanDerm；AgentClinic；MedDialogRubrics。